Practica 2

Introducción a la Ciencia de Datos. Máster en Ciencia de Datos- UV

Pablo Gallart Carbonell

2026-10-26

Índice

1. Configuración del los bloques (*Chunks*) 1

2. Instalación automática de paquetes 1

3. Introducción del trabajo 1

4. Ejercicio 1 1

5. Ejercicio 2 4

6. Ejercicio 3 8

7. Ejercicio 4 13

8. Ejercicio 5 16

9. Ejercicio 6 19

10. Ejercicio 7 20

11. Ejercicio 8 23

1. Configuración del los bloques (*Chunks*)

2. Instalación automática de paquetes

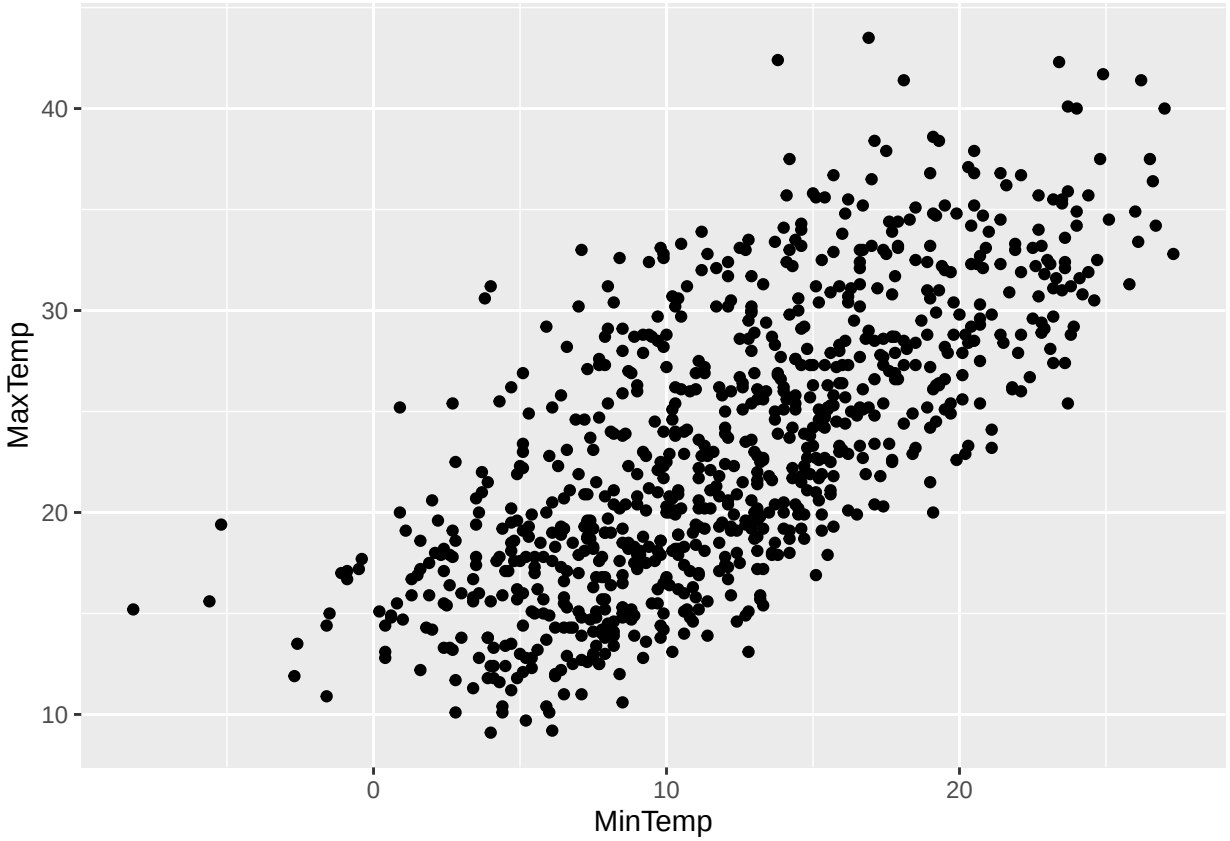
3. Introducción del trabajo

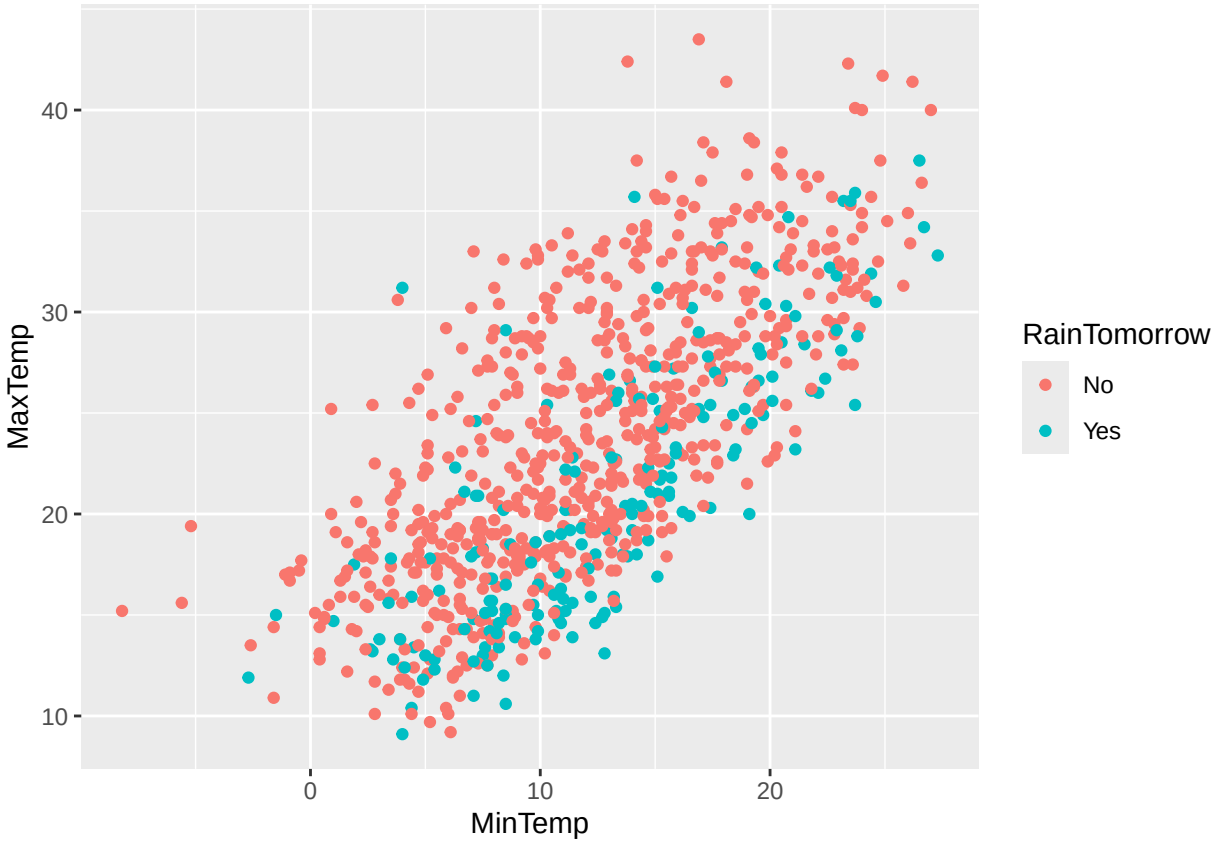
En esta práctica se utiliza la librería ggplot2 para construir gráficos en R a partir de una "gramática" basada en capas: un conjunto de datos, unas aesthetics (aes()) y un objeto geométrico (geom_*). Se trabaja con gráficos de dispersión, de línea (con barras de error), boxplots y violines, histogramas y gráficos de barras. En cada uno se personalizan títulos, ejes, colores, formas, leyendas y facetas, y los resultados se guardan en PDF con ggsave().

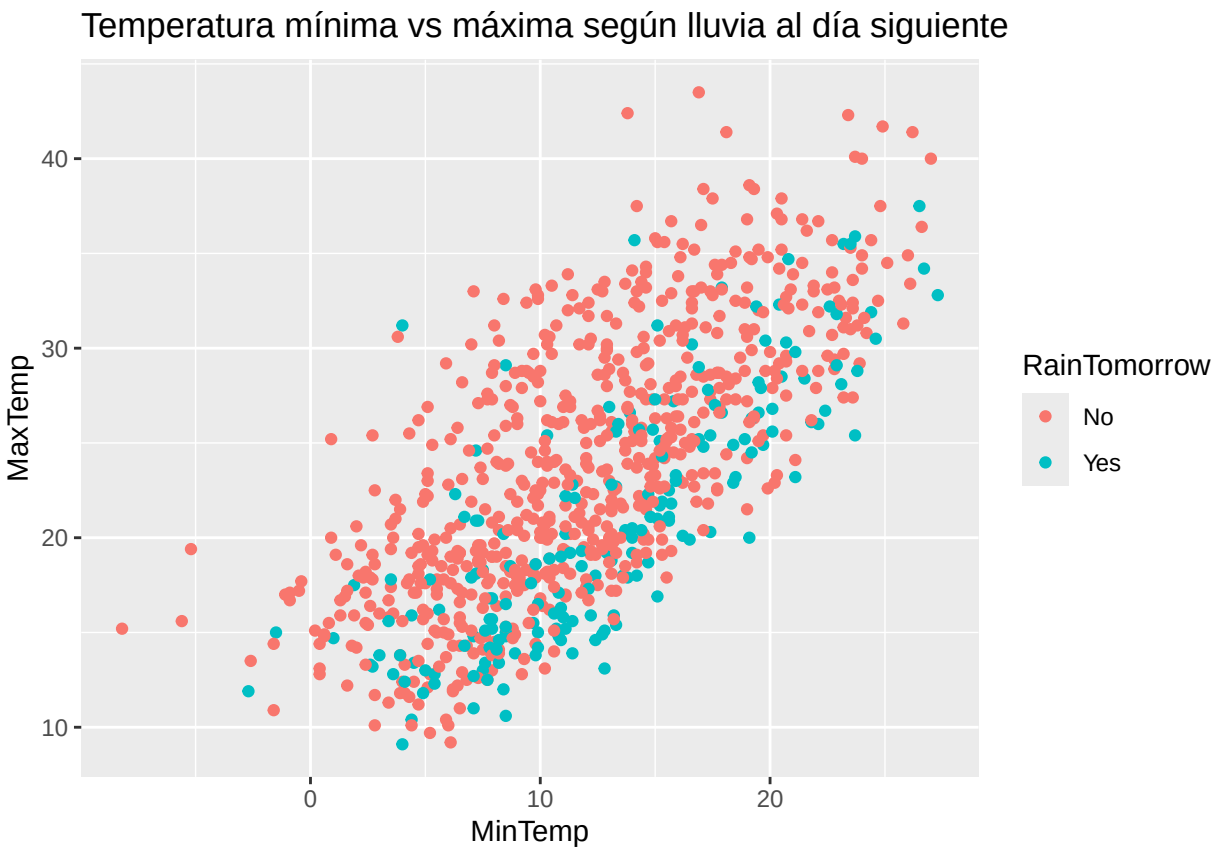
4. Ejercicio 1

Carga el fichero weatherAUS.RData utilizando lo aprendido en la práctica 1. Crea un objeto ggplot denominado grafico1 en el que esté definido el conjunto de datos ds alojado en el fichero weatherAUS.RData y un aesthetics

en el que en el eje x esté definida la variable MinTemp y en el eje y esté definida la variable MaxTemp. Añade una capa que defina el objeto geométrico necesario para construir un gráfico de dispersión de las variables MinTemp y MaxTemp. Genera ahora el mismo gráfico y almacénalo en grafico2 pero define el aesthetics para visualizar las variables MinTemp y MaxTemp en los ejes de la gráfica y la variable categórica RainTomorrow como el color. A partir del objeto grafico2, representa un gráfico de dispersión en el que se muestren los puntos con el color del punto correspondiente a la variable RainTomorrow. Añade a grafico2 una capa para incluir un título con ggtitle() y almacénalo en grafico3. Almacena en formato pdf el gráfico resultante en un fichero denominado Ejercicio1.pdf.

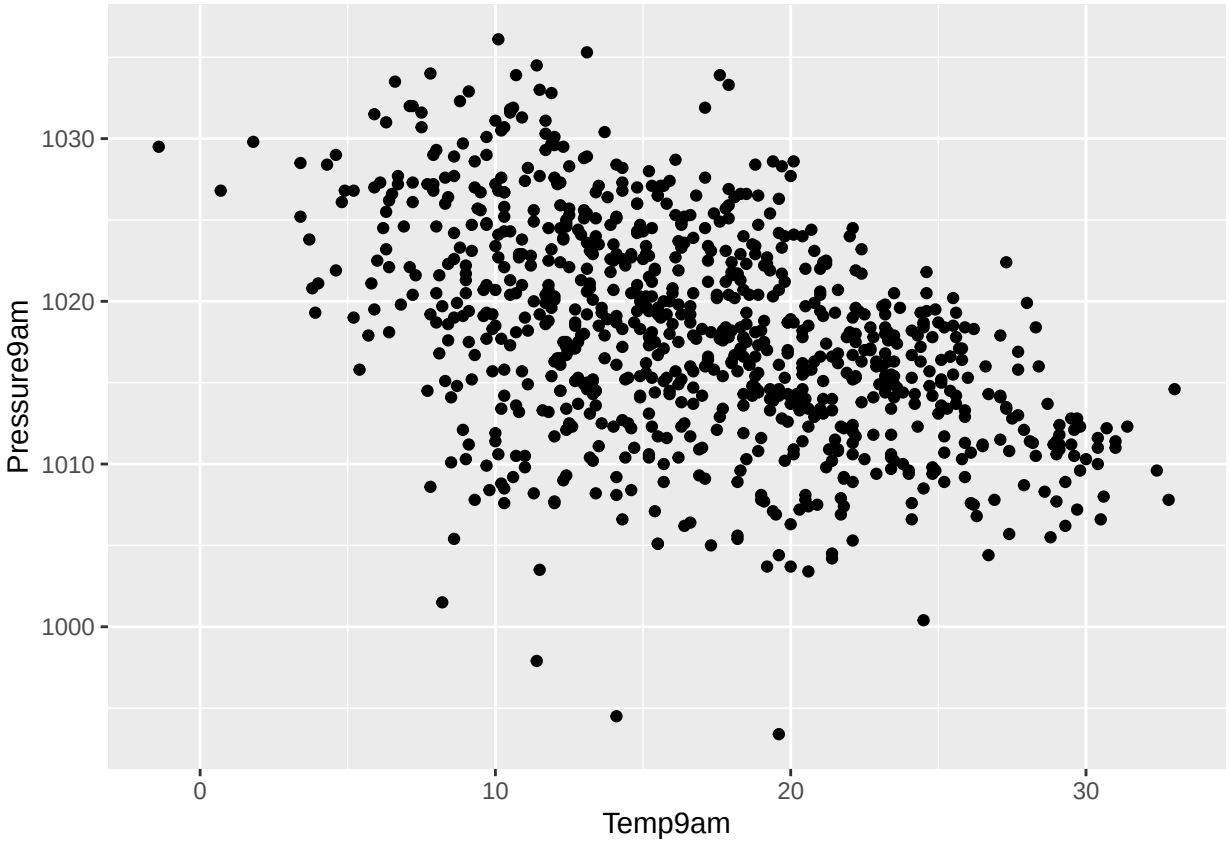


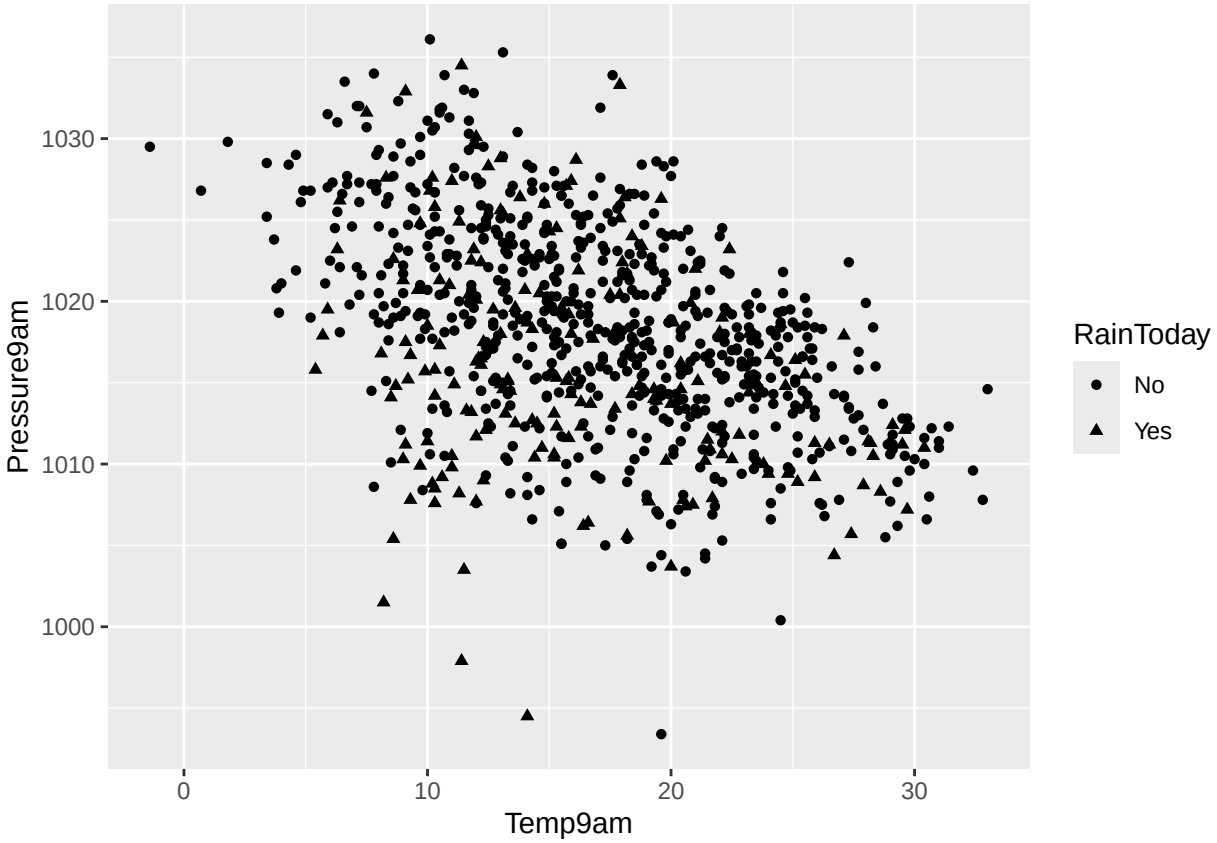

MaxTemp
40
30
20
10
0
10
20
MinTemp
RainTomorrow
No
Yes

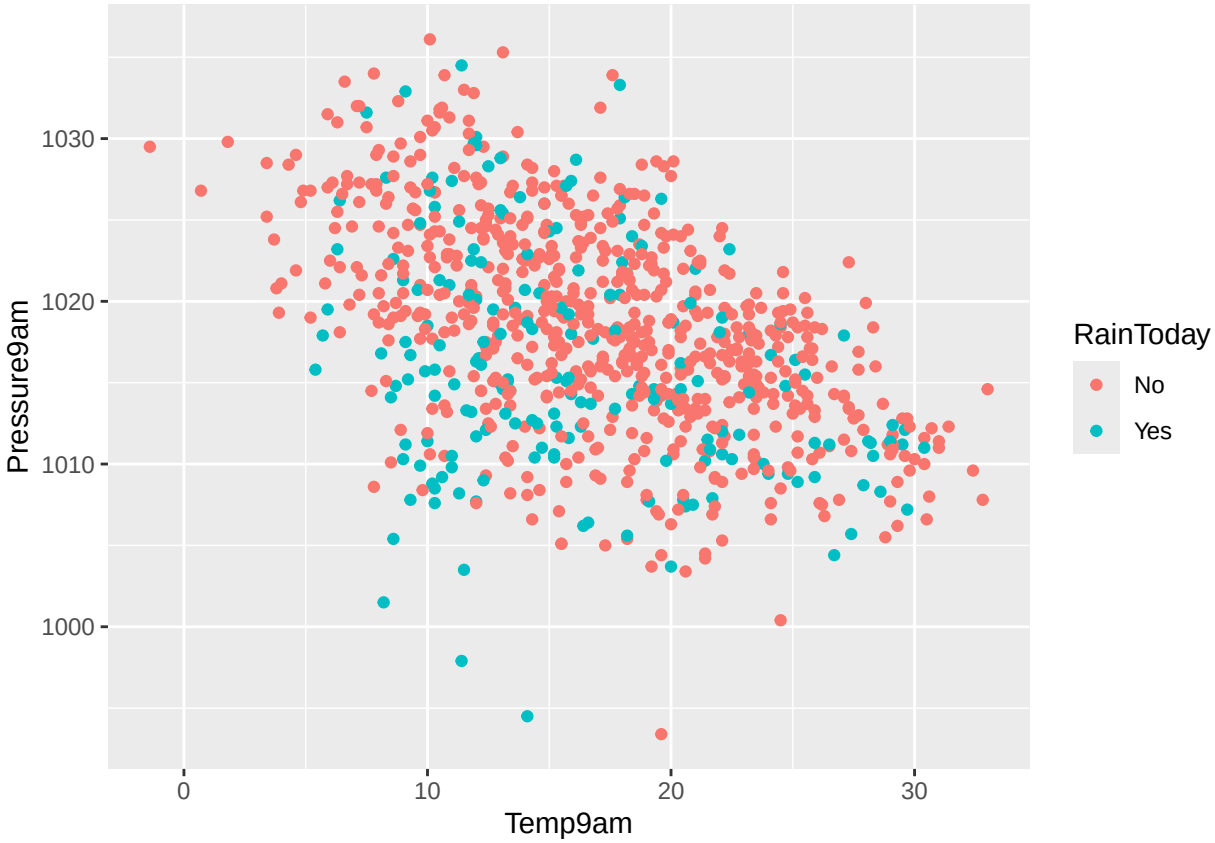


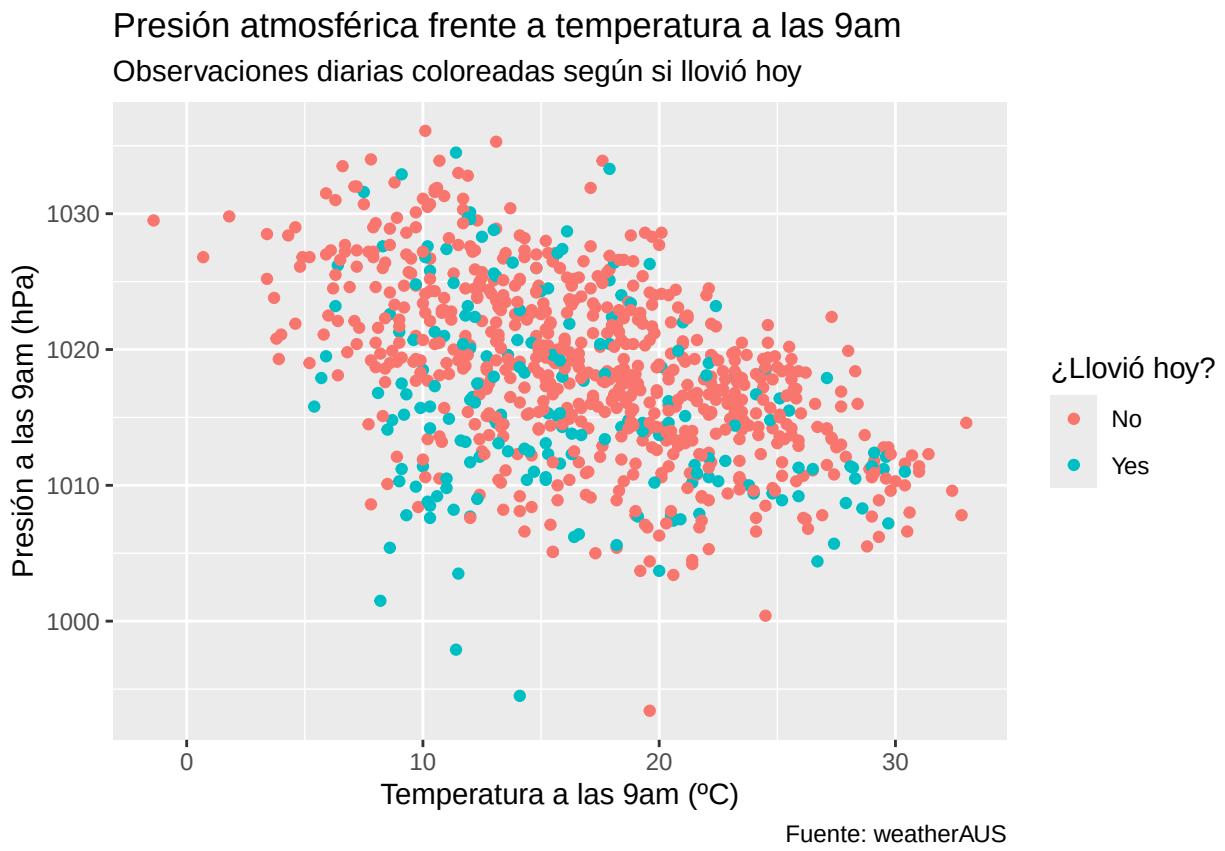
5. Ejercicio 2

Utilizando ggplot haz un grafico de dispersión en el que representes las variables Temp9am y Pressure9am en los ejes x e y respectivamente. Modifica el gráfico anterior para incluir información categórica proporcionada por la variable RainToday con la forma del punto. Modifica el gráfico anterior para incluir información categórica proporcionada por la variable RainToday con el color del punto. ¿Con qué representación (color o forma) se observa mejor la información que introduce la variable RainToday? Añade títulos explicativos al gráfico anterior (debe aparece un título, subtítulo, leyendas e información de las variables representadas en los ejes). Almacena en formato pdf el gráfico resultante en un fichero denominado Ejercicio2.pdf.


Pressure9am
1030
1020
1010
1000
0
10
20
30
Temp9am


Pressure9am
1030
1020
1010
1000
0
10
20
30
Temp9am
RainToday
No
Yes

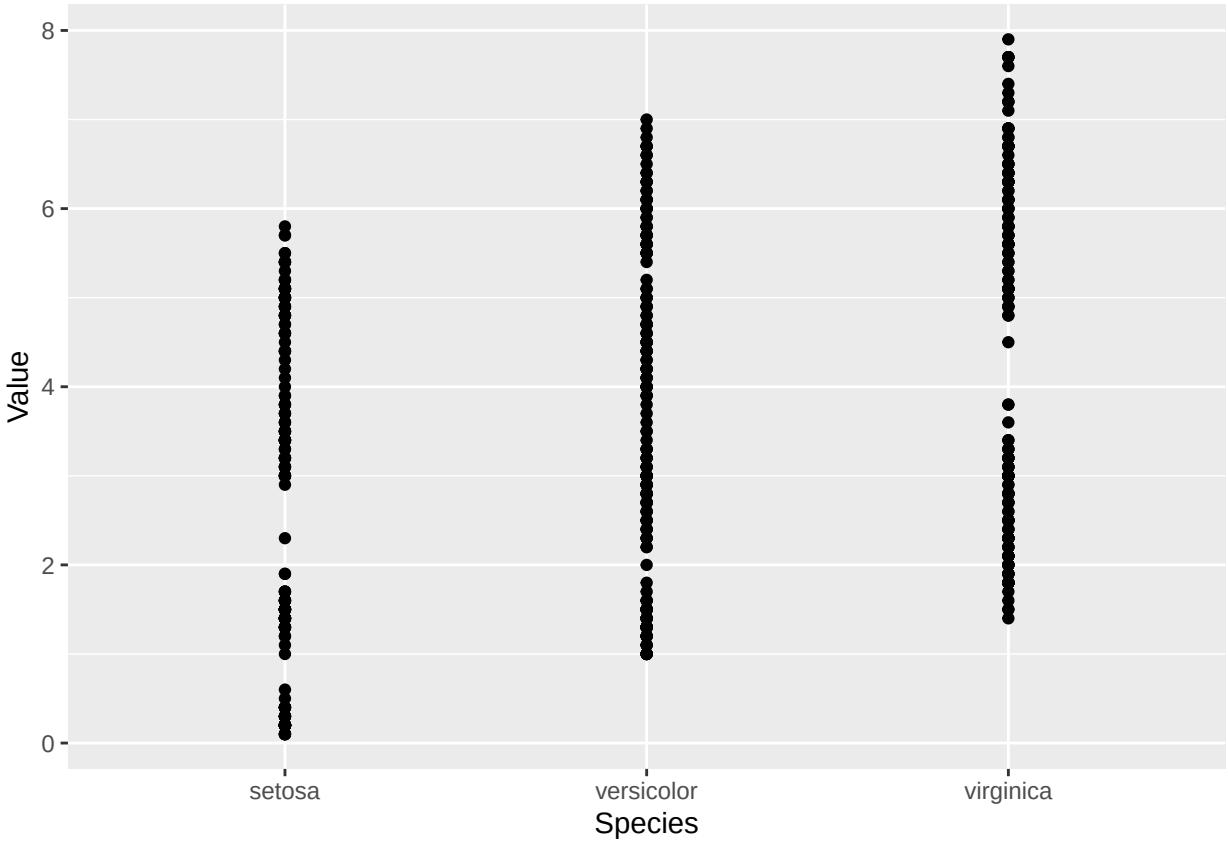

Pressure9am
1030
1020
1010
1000
0
10
20
30
Temp9am
RainToday
No
Yes

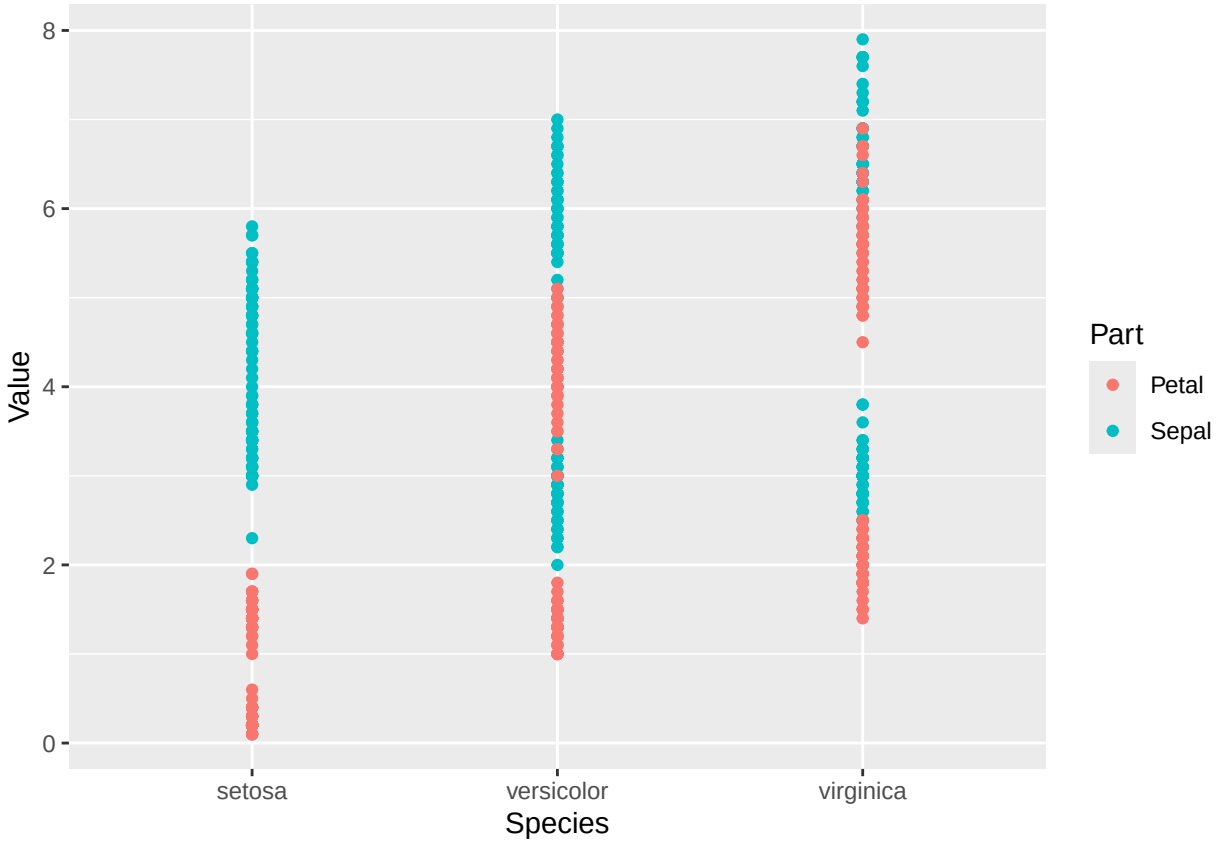


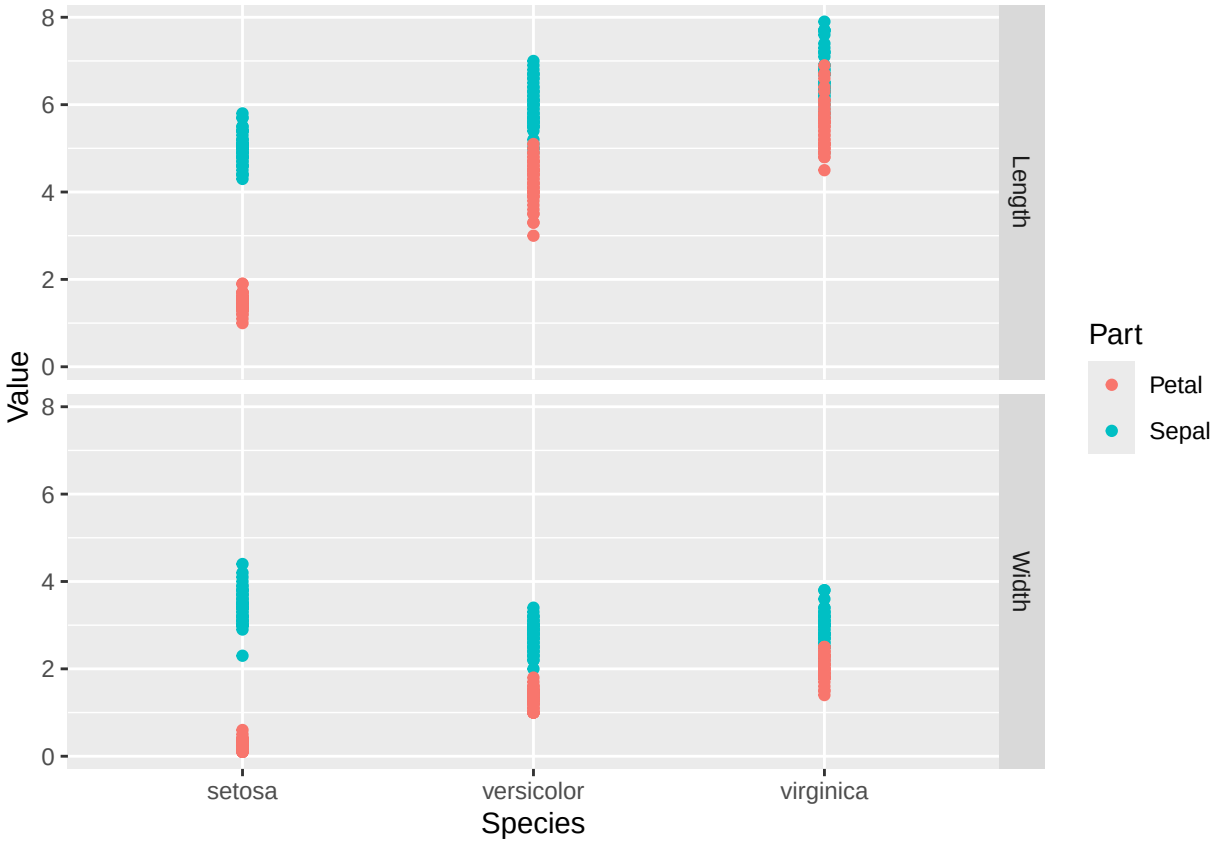
6. Ejercicio 3

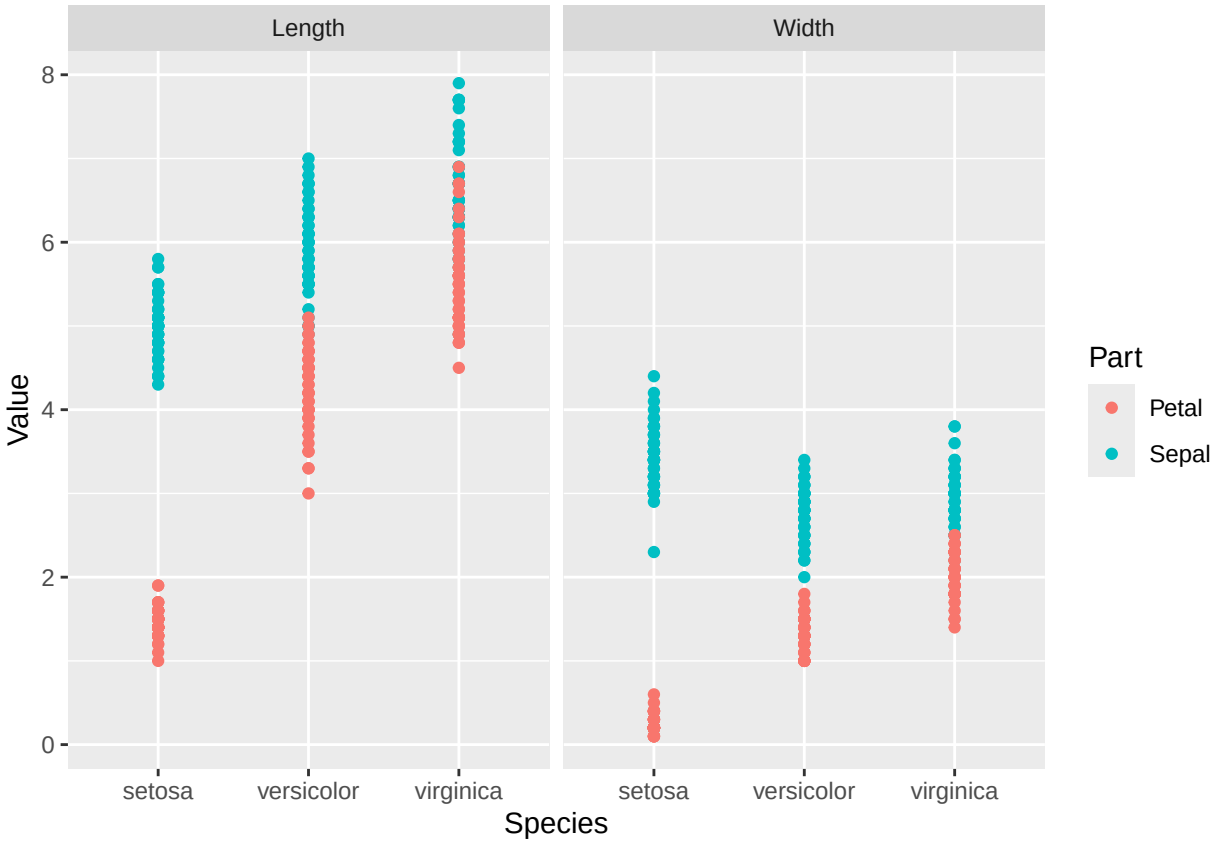
Carga el fichero iris.tidy.Rdata utilizando lo aprendido en la práctica 1. Utiliza la función str() para ver qué variables contiene el dataset. Crea un objeto ggplot denominado iris.grafico1 en el que esté definido el conjunto de datos iris.tidy alojado en el fichero iris.tidy.RData y un aesthetics en el que en el eje x esté definida la variable Species y en el eje y esté definida la variable Value. Añade una capa que defina el objeto geométrico necesario para construir un gráfico de dispersión de las variables Species y Value. Modifica el aesthetics de iris.grafico1 para visualizar la variable categórica Part y almacénalo en iris.grafico2. A partir del objeto iris.grafico2, representa un gráfico de dispersión en el que se muestren los puntos dados por las variables Species y Value, y el color del punto se corresponda con el valor de la variable Part. Incluye información de la variable Measure haciendo dos gráficos de dispersión (dispuestos en filas) con facet_grid(), como en el apartado de introducción, para los dos valores que toma la variable Measure. Prueba a cambiar la disposición de los gráficos para que sea en columnas ¿Qué disposición, en filas o en columnas, permite comparar mejor los valores de las dos variables? Cambia ahora la capa geom_point() del gráfico anterior por la capa geom_jitter(). ¿Qué diferencia observas? Almacena en formato pdf el gráfico resultante en un fichero denominado Ejercicio3.pdf.

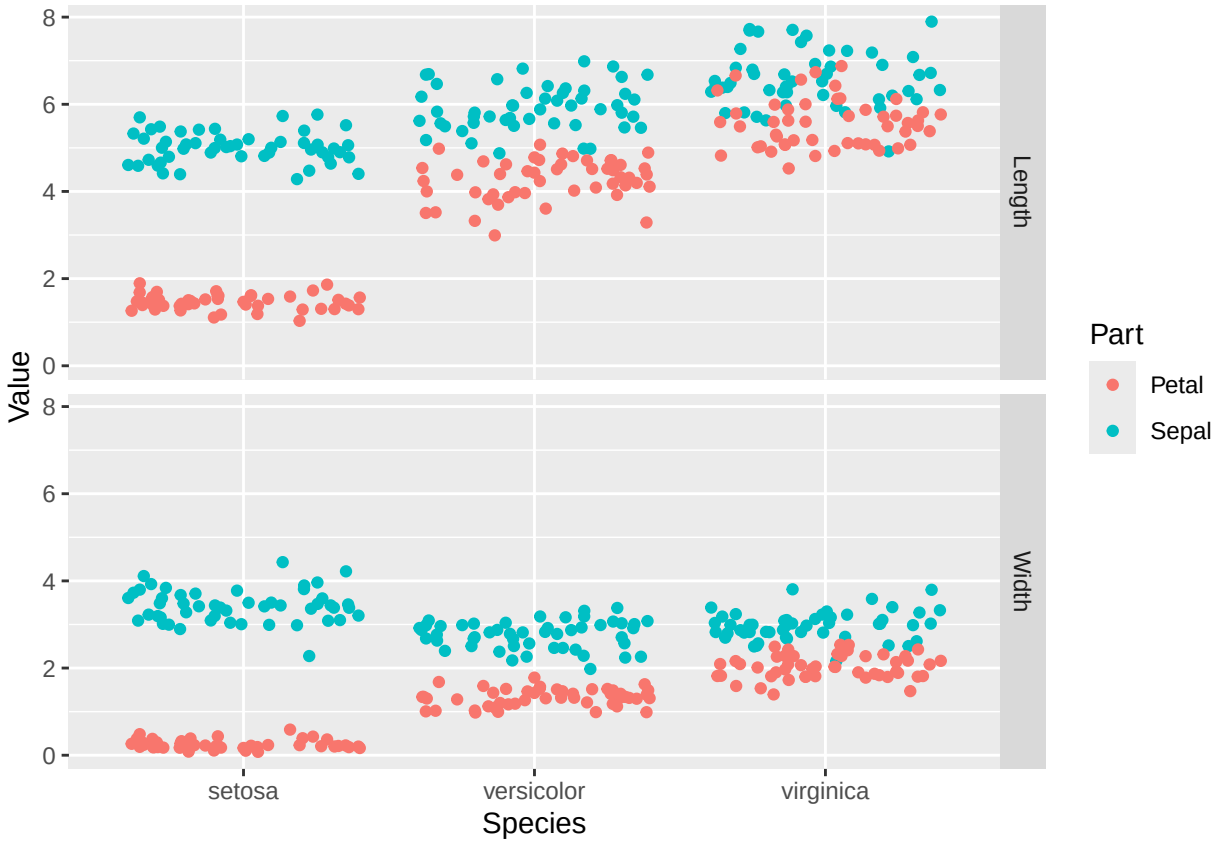
```
'data.frame':   600 obs. of  4 variables:
 $ Species: Factor w/ 3 levels "setosa","versicolor",..: 1 1 1 1 1 1 1 1 1 1 ...
 $ Part   : Factor w/ 2 levels "Petal","Sepal": 2 2 2 2 2 2 2 2 2 2 ...
 $ Measure: chr  "Length" "Length" "Length" "Length" ...
 $ Value  : num  5.1 4.9 4.7 4.6 5 5.4 4.6 5 4.4 4.9 ...
```


8
6
4
2
0
Value
setosa
versicolor
virginica
Species


8
6
4
2
0
Value
setosa
versicolor
virginica
Species
Part
Petal
Sepal


Value
8
6
4
2
0
Length
Width
setosa
versicolor
virginica
Species
Part
Petal
Sepal


Length
Width
8
6
4
2
0
Value
setosa
versicolor
virginica
setosa
versicolor
virginica
Species
Part
Petal
Sepal

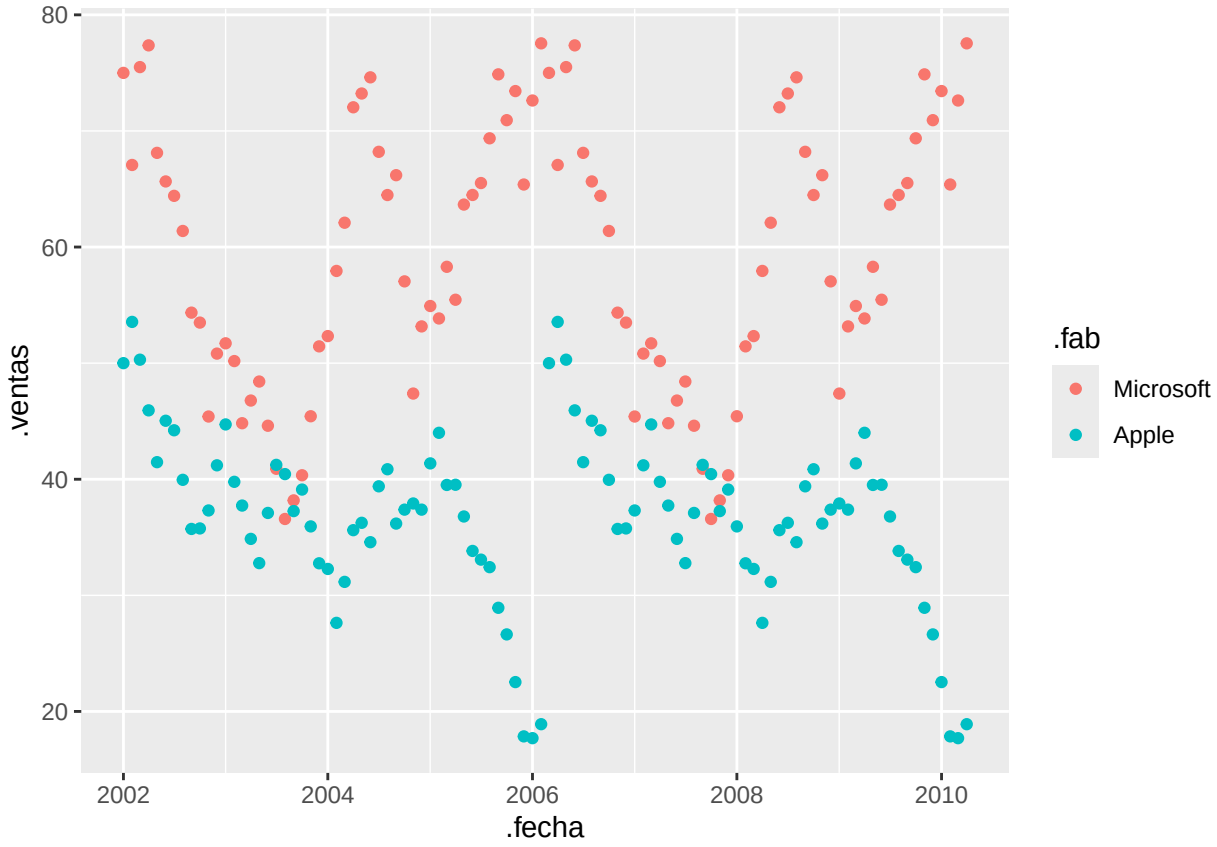


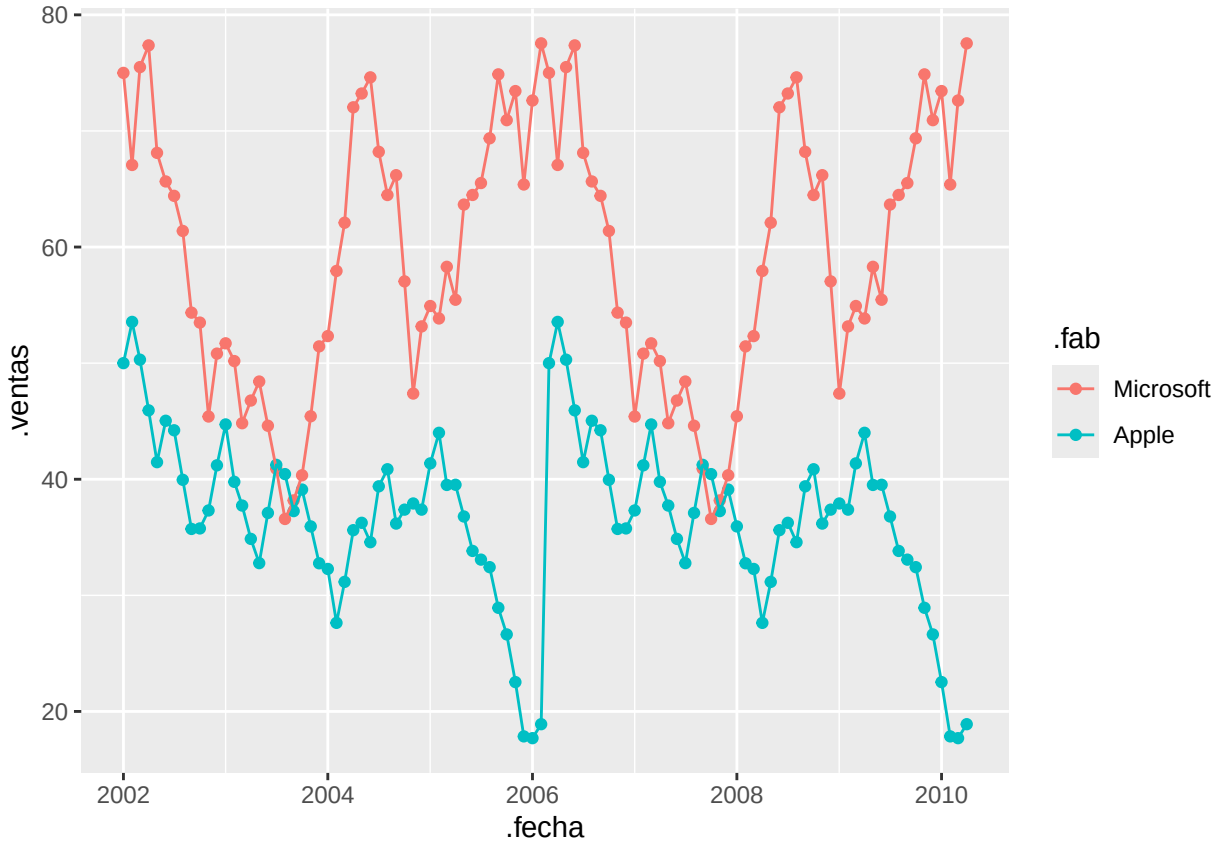
7. Ejercicio 4

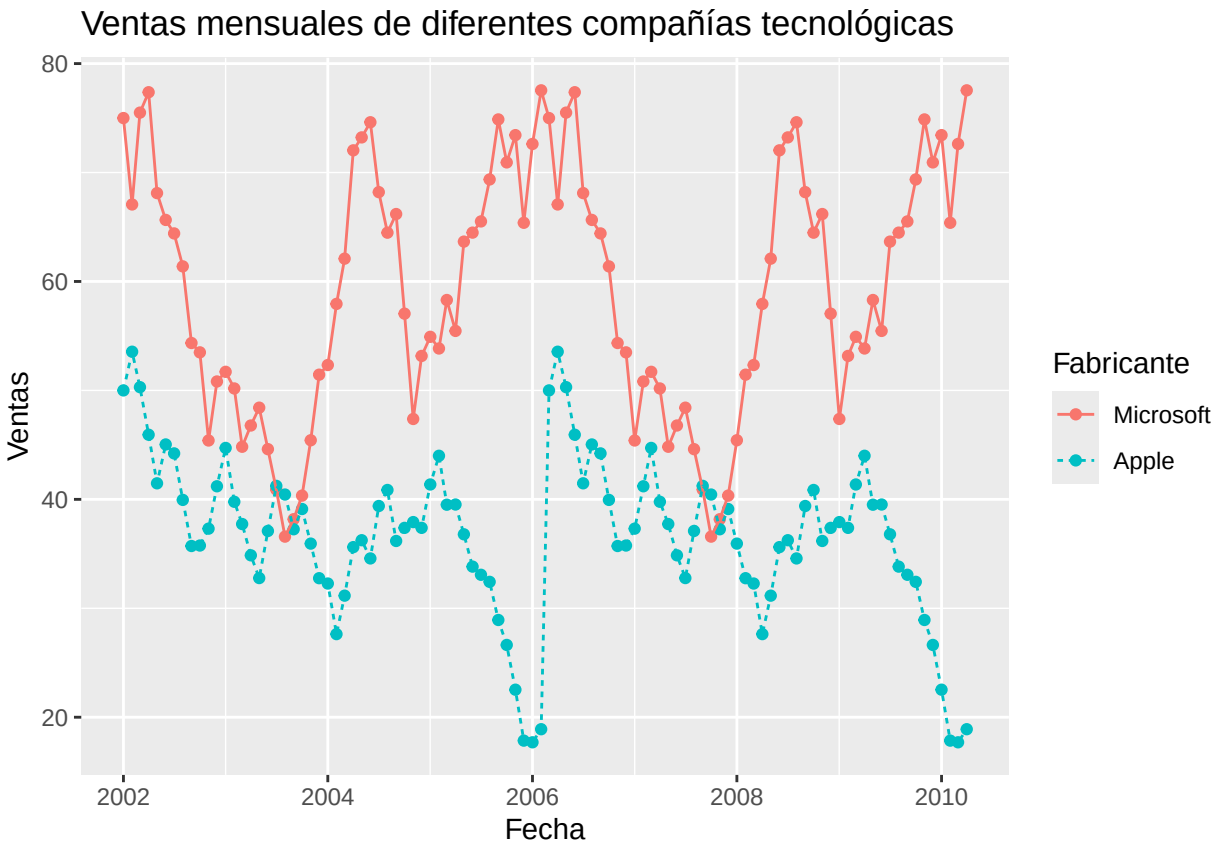
Carga el fichero Ejercicio4_Data.Rdata. Examina las variables que tiene dicho dataset. Representa un gráfico de puntos, en el que se muestre la fecha en el eje x y las ventas en el eje y . Queremos que los datos de cada fabricante sean de un color distinto. ¿Es este gráfico válido para evaluar la evolución de las ventas de cada fabricante? Representa un gráfico como el anterior en el que se muestre la línea que une los puntos que antes has representado. Modifica el gráfico anterior para que la tendencia de cada fabricante este trazada con un tipo de línea diferente. Añade el siguiente título al gráfico "Ventas mensuales de diferentes compañías tecnológicas". Almacena en formato pdf el gráfico resultante en un fichero denominado Ejercicio4.pdf.

```
 [1] "DatosEjer4"    "ds"            "g2"            "g3"            "grafico1"      "grafico2"
 [7] "grafico3"      "iris.grafico1" "iris.grafico2" "iris.tidy"     "load"          "params"
```

```
'data.frame':   200 obs. of  3 variables:
 $ Fecha     : Date, format: "2002-01-01" "2002-02-01" "2002-03-01" ...
 $ Fabricante: Factor w/ 2 levels "Microsoft","Apple": 1 1 1 1 1 1 1 1 1 1 ...
 $ Ventas    : num  75 67.1 75.5 77.4 68.1 ...
```


80
60
40
20
.ventas
2002
2004
2006
2008
2010
.fecha
.fab
Microsoft
Apple


80
60
40
20
.ventas
2002
2004
2006
2008
2010
.fecha
.fab
Microsoft
Apple



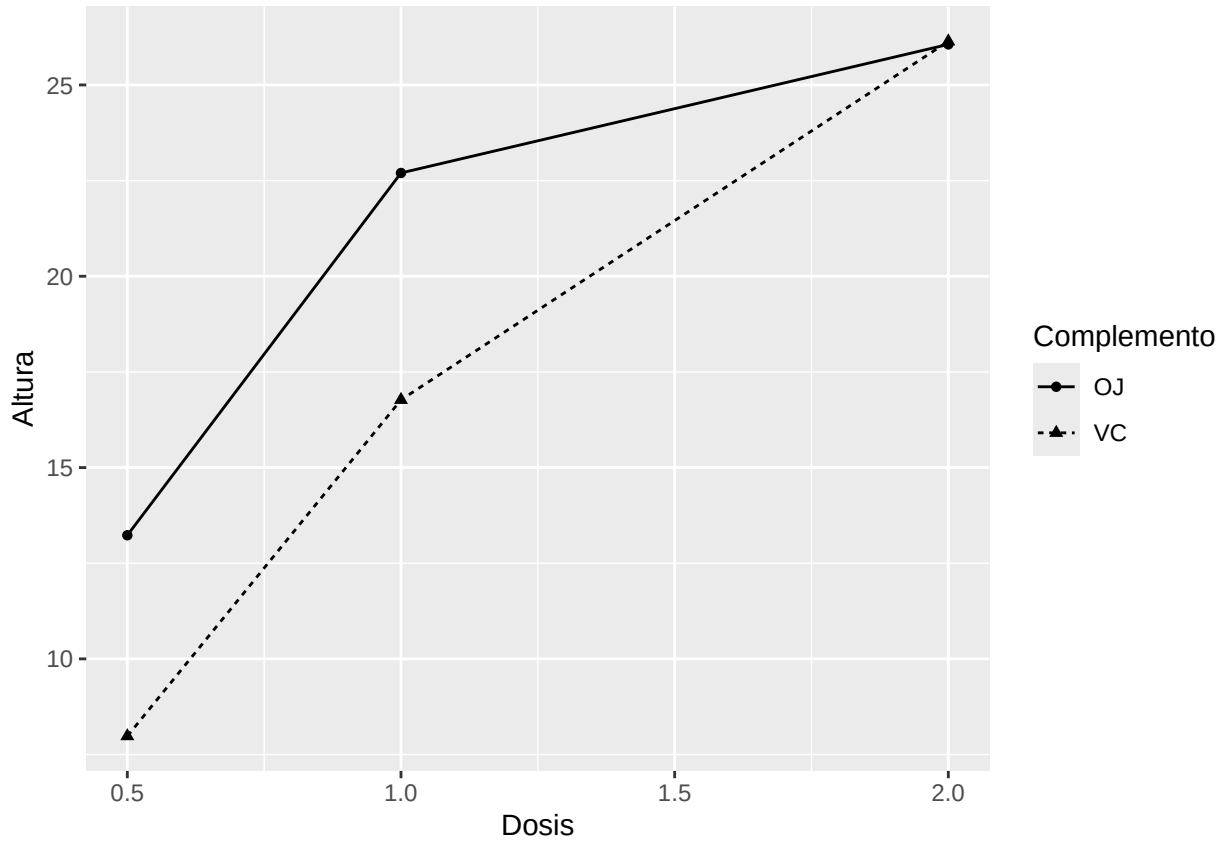
8. Ejercicio 5

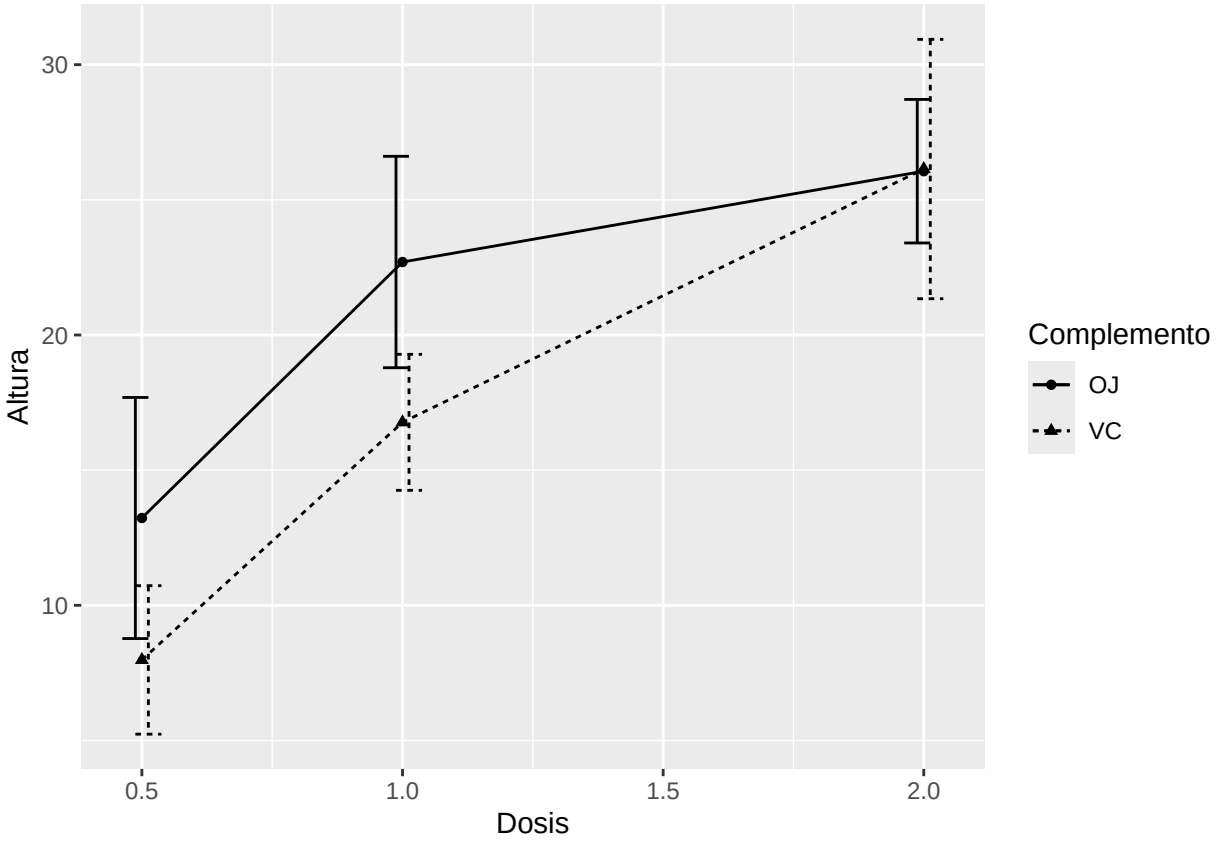
Añadir barras de error a un gráfico de línea.

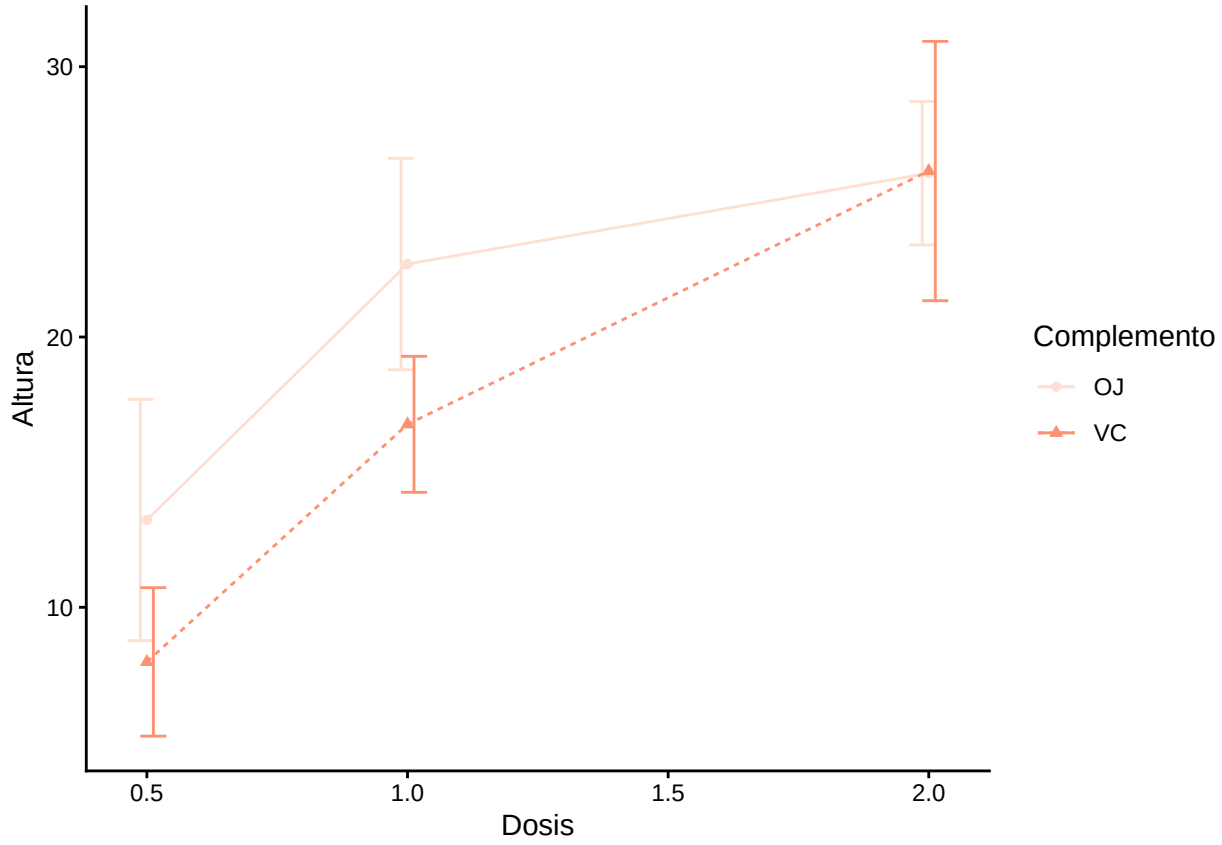
Carga el fichero Experimento.Rdata. Examina las variables que tiene dicho dataset. Representa un gráfico de puntos, en el que se muestre la Dosis en el eje x y la Altura en el eje y . Queremos que los datos de cada Complemento se representen en una línea diferente con diferentes trazos. Hazlo incluyendo las opciones de tipo de línea y forma del punto dentro del aes() de la capa ggplot. Crea otro gráfico añadiendo al gráfico anterior barras de error en cada punto. El error viene dado por la variable Error_Altura. Crea otro gráfico, como el anterior (idéntico), pero en este caso no puedes incluir el tipo de línea y el tipo de punto en aes() de la capa ggplot. Además queremos que la paleta de colores sea en tonos de rojos (scale_color_brewer). Almacena en formato pdf el gráfico resultante en un fichero denominado Ejercicio5.pdf.

```
 [1] "col_fab"       "col_fecha"     "col_ventas"    "d4"            "DatosEjer4"    "ds"
 [7] "Experimento"   "g2"            "g3"            "g4"            "grafico1"      "grafico2"
[13] "grafico3"      "iris.grafico1" "iris.grafico2" "iris.tidy"     "load"          "params"
```

```
'data.frame':   6 obs. of  4 variables:
 $ Complemento : Factor w/ 2 levels "OJ","VC": 1 1 1 2 2 2
 $ Dosis       : num  0.5 1 2 0.5 1 2
 $ Altura      : num  13.23 22.7 26.06 7.98 16.77 ...
 $ Error_Altura: num  4.46 3.91 2.66 2.75 2.52 ...
```


25
20
15
10
Altura
0.5
1.0
1.5
2.0
Dosis
Complemento
OJ
VC


30
20
10
Altura
0.5
1.0
1.5
2.0
Dosis
Complemento
OJ
VC

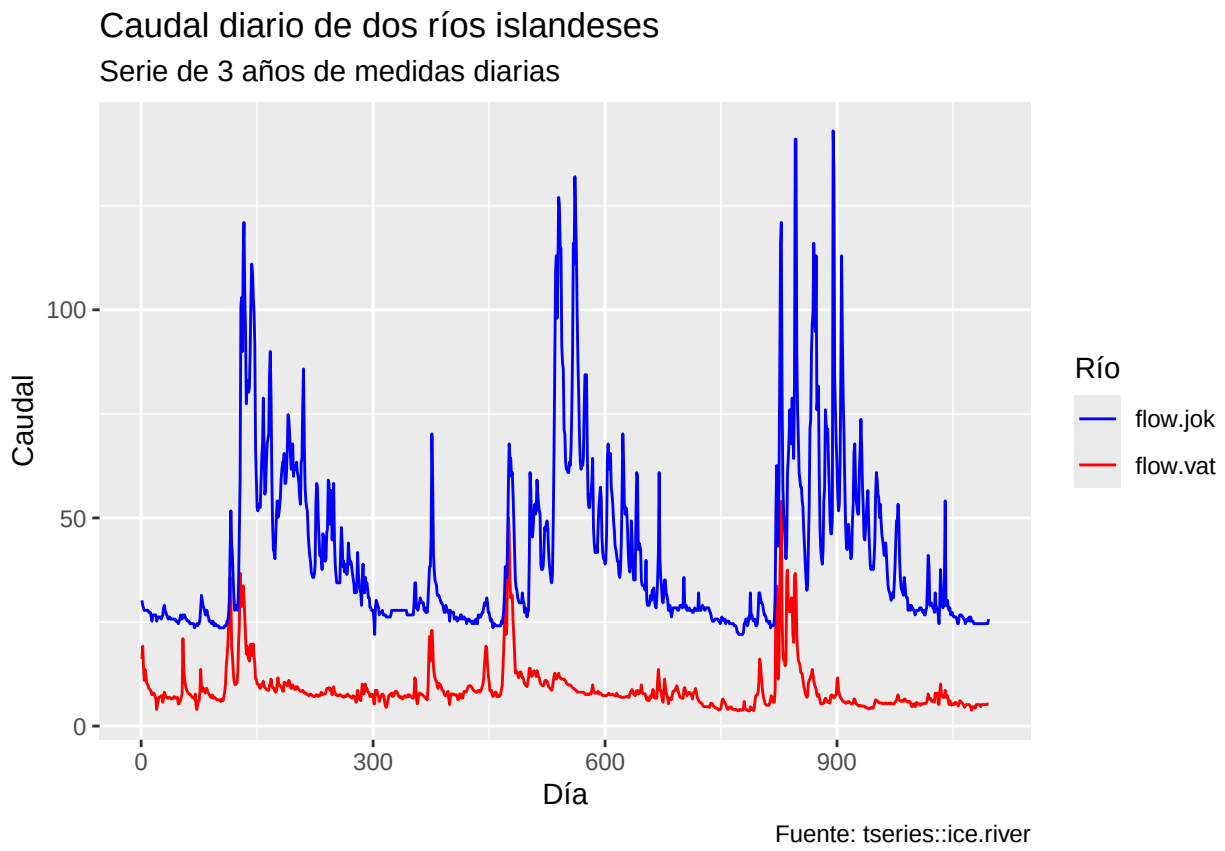


9. Ejercicio 6

El fichero iceRiver.RData contiene información del caudal de dos ríos islandeses medidos a diarios durante 3 años. Puedes obtener información detallada de las variables usando > ?tseries::ice.river

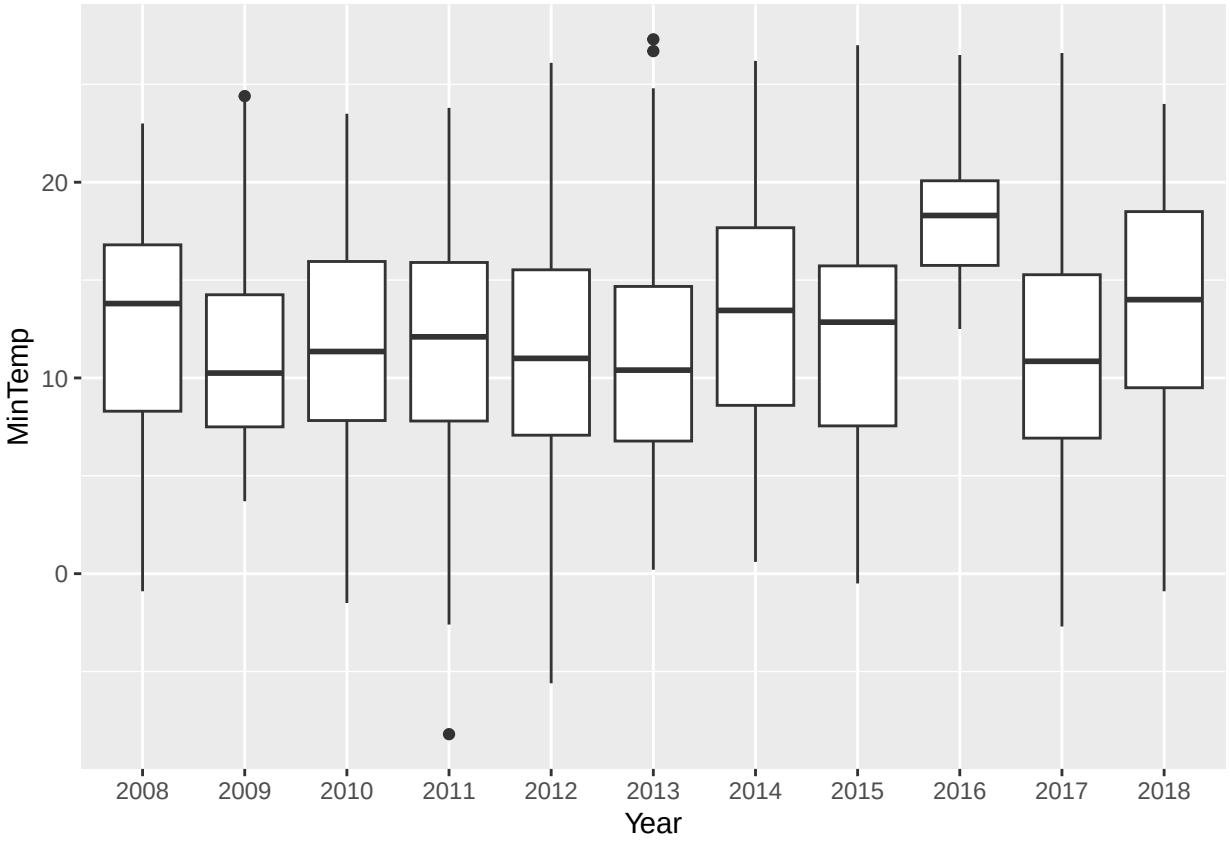
Representa el caudal de ambos ríos a lo largo del período considerado coloreando una serie (flow.vat) en color rojo y la otra en color azul. Utiliza la función labs para enriquecer el gráfico. Almacena en formato pdf el gráfico resultante en un fichero denominado Ejercicio6.pdf.

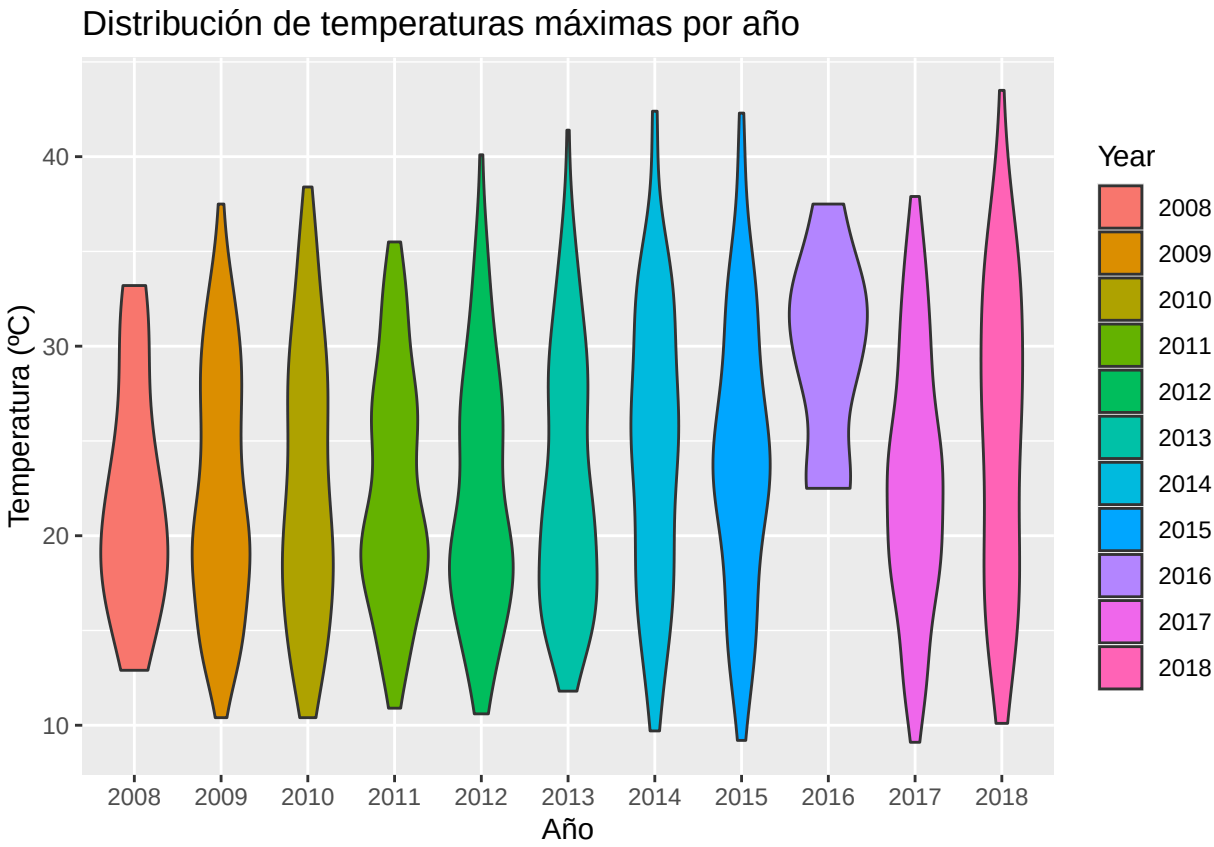
```
 [1] "col_fab"       "col_fecha"     "col_ventas"    "d4"            "d5"            "DatosEjer4"
 [7] "ds"            "Experimento"   "g2"            "g3"            "g4"            "g5"
[13] "grafico1"      "grafico2"      "grafico3"      "ice.river.df"  "iris.grafico1" "iris.grafico2"
[19] "iris.tidy"     "load"          "params"
```

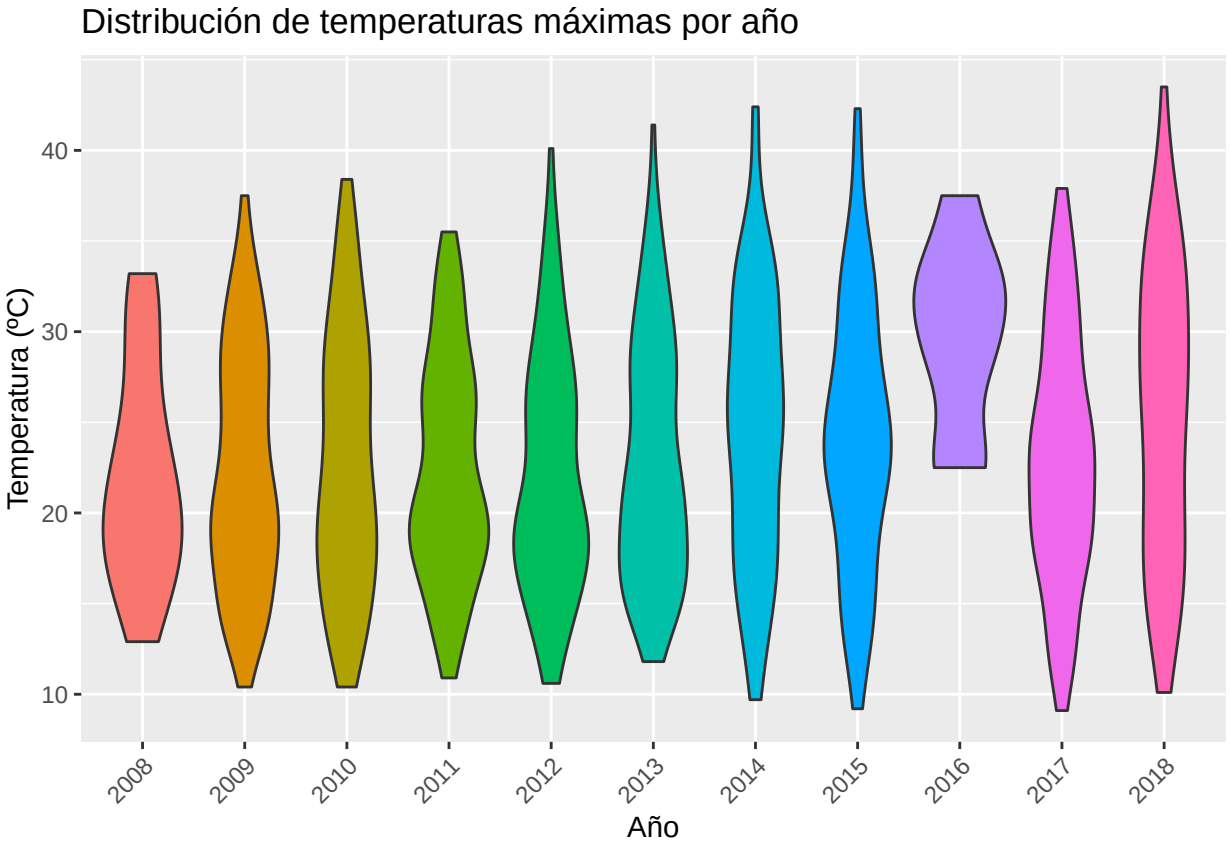


10. Ejercicio 7

Carga el fichero weatherAUS_distributions.RData. Crea un gráfico en el que estén los boxplots de la variable MinTemp para cada uno de los años presentes en la variable Year del dataset. Crea un gráfico en el que estén los gráficos de violín de la variable MaxTemp para cada uno de los años presentes en la variable Year del dataset. Añade en el mismo gráfico una capa de etiquetas de título (Distribución de temperaturas máximas por año), eje x (Año) y eje y (Temperatura (ºC)). Colorea el interior de los violines según la la variable Year. En el gráfico anterior elimina la leyenda y coloca los años en el eje x a 45 grados de inclinación. Busca información sobre cómo hacer esto. Almacena en formato pdf el gráfico resultante en un fichero denominado Ejercicio7.pdf.


MinTemp
20
10
0
2008
2009
2010
2011
2012
2013
2014
2015
2016
2017
2018
Year

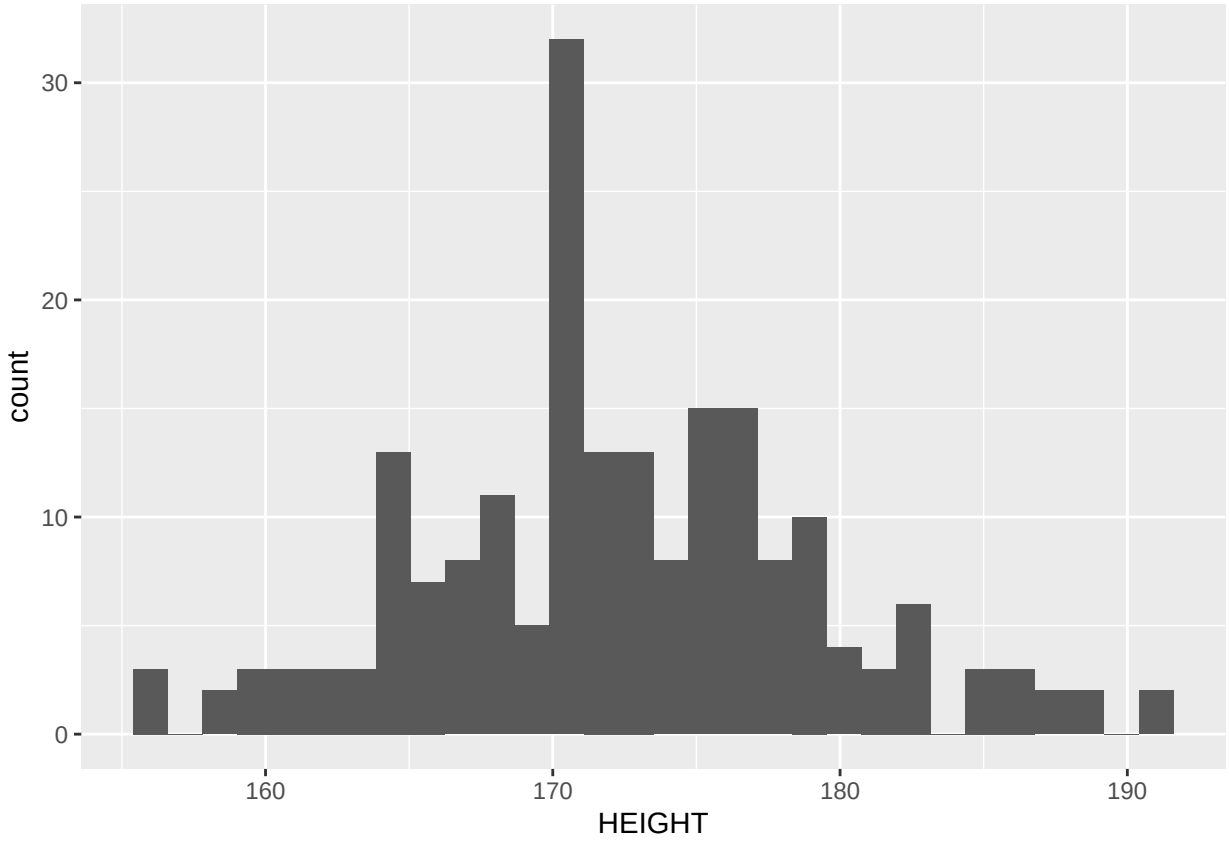

Distribución de temperaturas máximas por año
Temperatura (ºC)
40
30
20
10
2008
2009
2010
2011
2012
2013
2014
2015
2016
2017
2018
Año
Year
2008
2009
2010
2011
2012
2013
2014
2015
2016
2017
2018

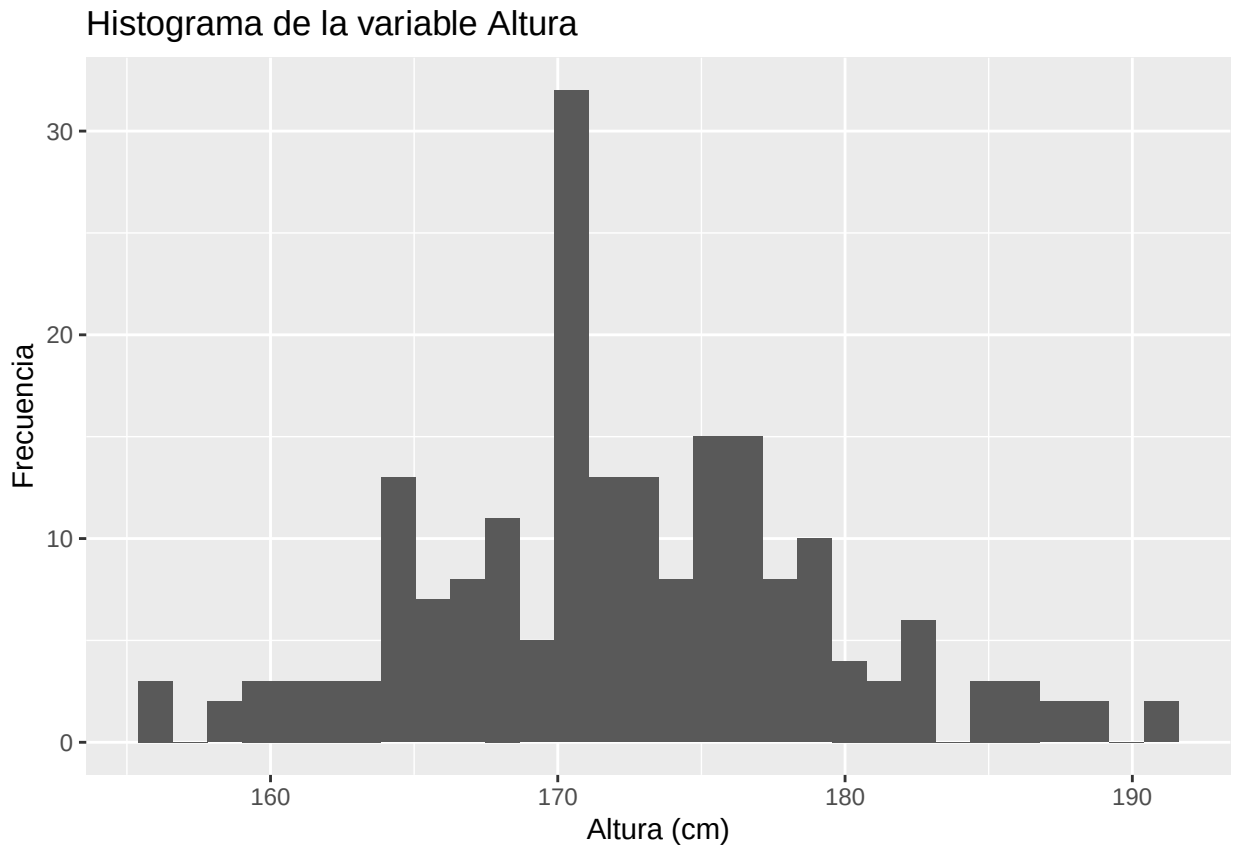


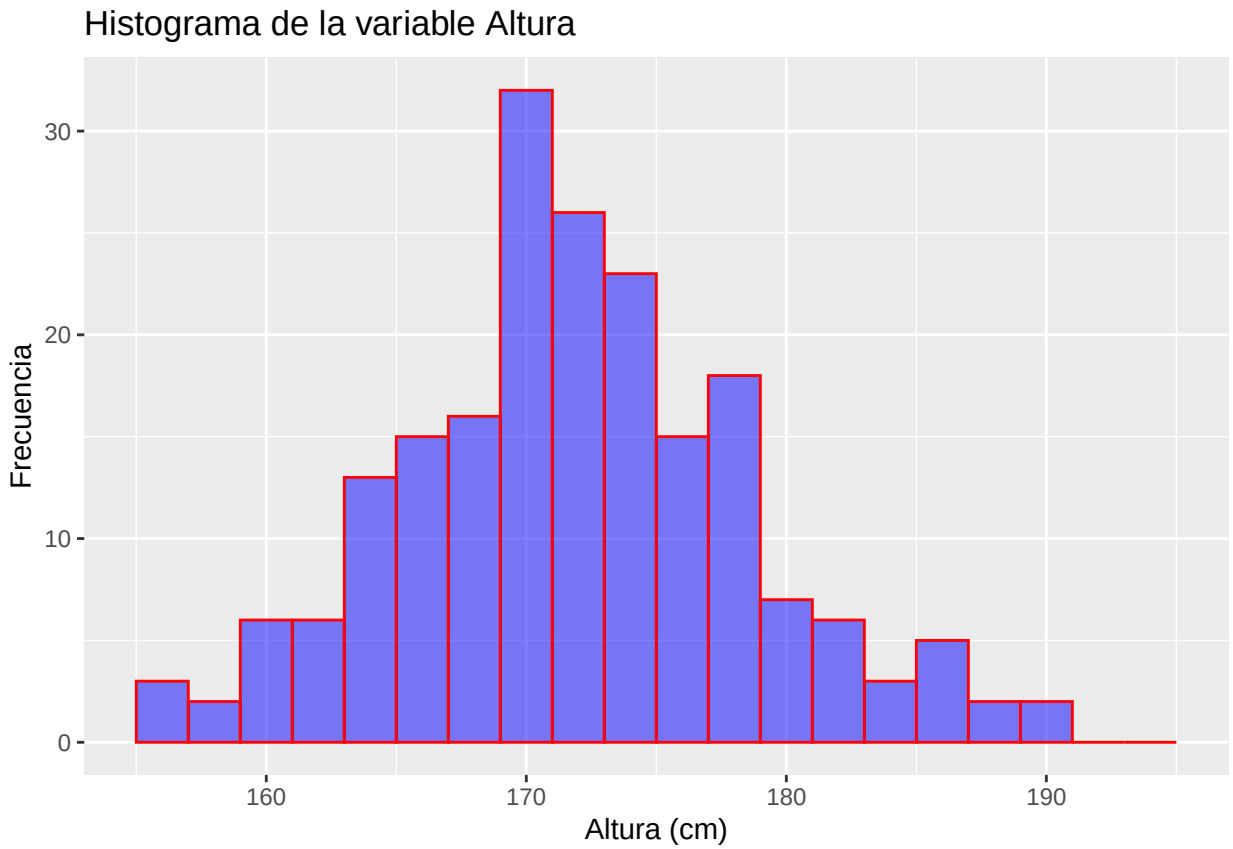
11. Ejercicio 8

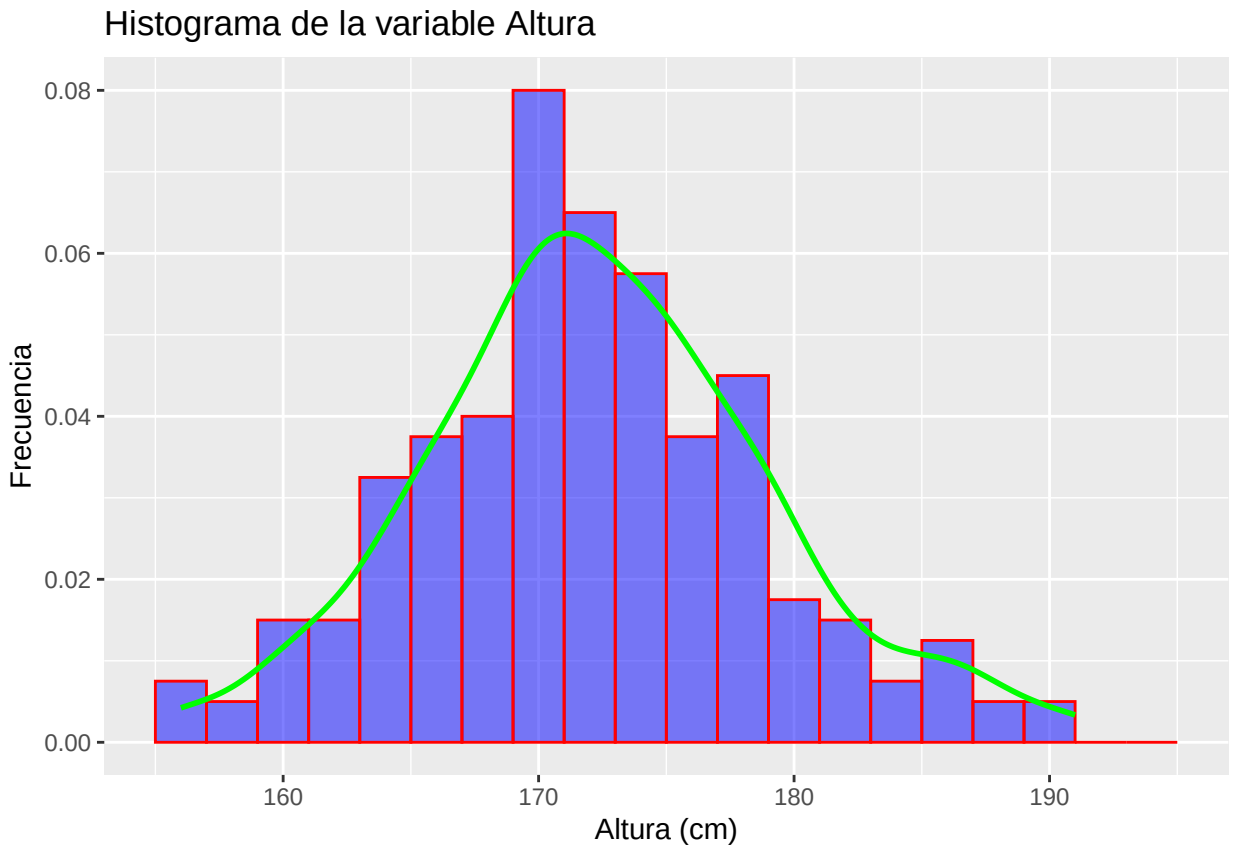
Descarga de la url "http://assets.datacamp.com/blog_assets/chol.txt" el dataset de Datacamp que utilizarás para este ejercicio y cárgalo en un datafrae . Representa el histograma de la variable HEIGHT del dataframe cargado del fichero anterior. Añade título ("Histograma de la variable Altura"), una etiqueta en el eje x ("Altura (cm)") y una etiqueta en el eje y ("Frecuencia"). Ajusta el rango de representación entre 155 y 195, además fuerza que el histograma tenga 20 bins.(usa parámetro breaks) Haz que las barras del histograma sean de color azul con una grado de transparencia del 50 % y el contorno de color rojo. Añade la curva de distribución estimada de color verde. Representa el mismo histograma del apartado anterior para cada valor de la variable MORT, recuerda utilizar la función facet_grid(). Almacena en formato pdf el gráfico resultante en un fichero denominado Ejercicio8.pdf.

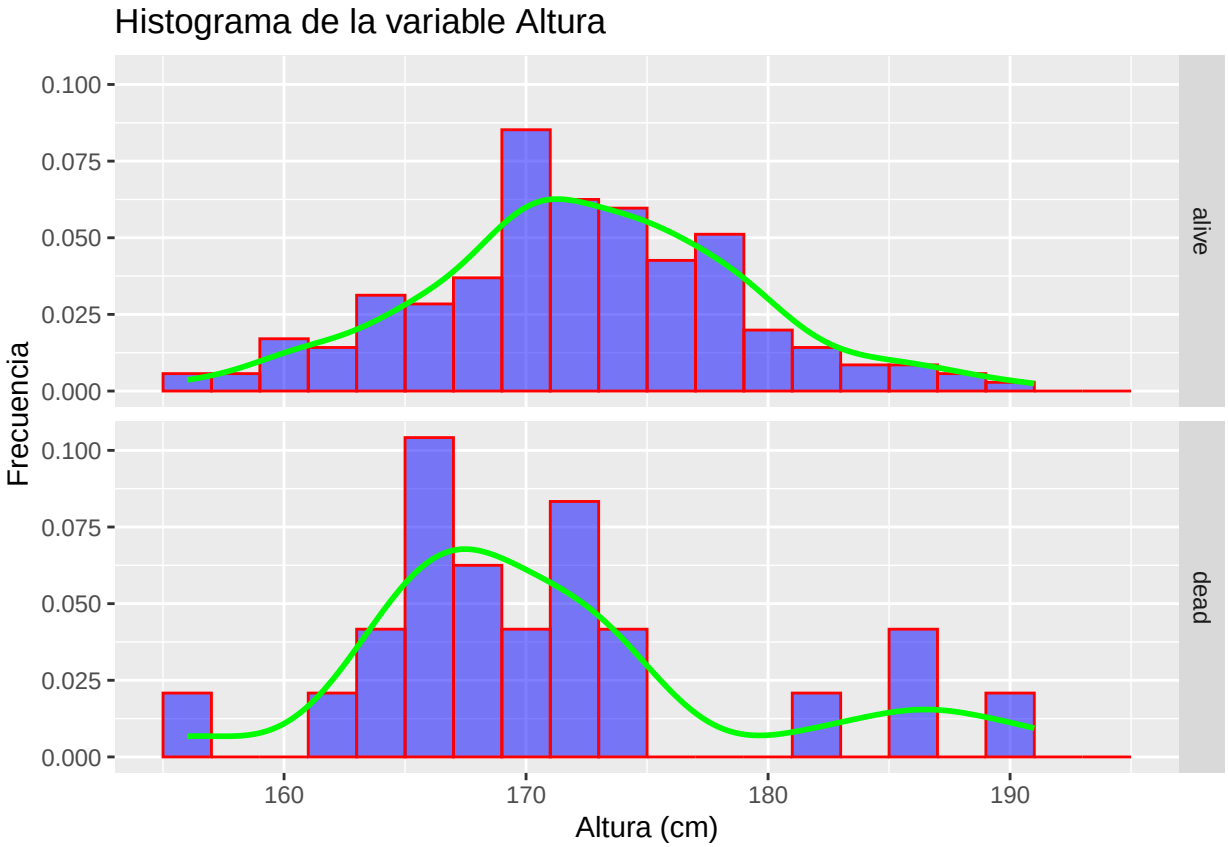
```
'data.frame':   200 obs. of  7 variables:
 $ AGE   : int  20 53 44 37 26 41 39 28 33 39 ...
 $ HEIGHT: int  176 167 170 173 170 165 174 171 180 166 ...
 $ WEIGHT: int  77 56 80 89 71 62 75 68 100 74 ...
 $ CHOL  : int  195 250 304 178 206 284 232 152 209 150 ...
 $ SMOKE : chr  "nonsmo" "sigare" "sigare" "nonsmo" ...
 $ BLOOD : chr  "b" "o" "a" "o" ...
 $ MORT  : chr  "alive" "dead" "dead" "alive" ...
```


30
20
10
0
count
160
170
180
190
HEIGHT


Histograma de la variable Altura
Frecuencia
30
20
10
0
160
170
180
190
Altura (cm)


Histograma de la variable Altura
Frecuencia
30
20
10
0
160
170
180
190
Altura (cm)


Histograma de la variable Altura
Frecuencia
0.08
0.06
0.04
0.02
0.00
160
170
180
190
Altura (cm)


Histograma de la variable Altura
Frecuencia
0.100
0.075
0.050
0.025
0.000
alive
dead
160
170
180
190
Altura (cm)